ADL—NN basics

2019年3月5日　　上午 09:15

- function越複雜越難訓練
  - function無限多種要嘗試
  - 系統化評估好的function? model長怎樣?怎麼找好的function?
- Model architecture
  - 二分類/是否independent或相依/yes no
  - 不同維度上面的轉換 (M-dim input，N-dim output)，目前還沒辦法讓model學到hyperparameters，目前還需要人工(有研究再做)
    - 學到兩組之間的mapping (weigted-sum)
    - 每個神經元都只會做一件小事情 EX: bias=>一定會讓這個數值加進去
    - 有bias可以讓輸出必定至少有一定的數值，bias越大可以讓af越靠右邊，類似一種prior，因為他可能更常出現，所以可以調整z一開始的value讓值盡可能再sigmoid是接近1的，如果有domain knowledge就可以調整af靠0或靠右
    - 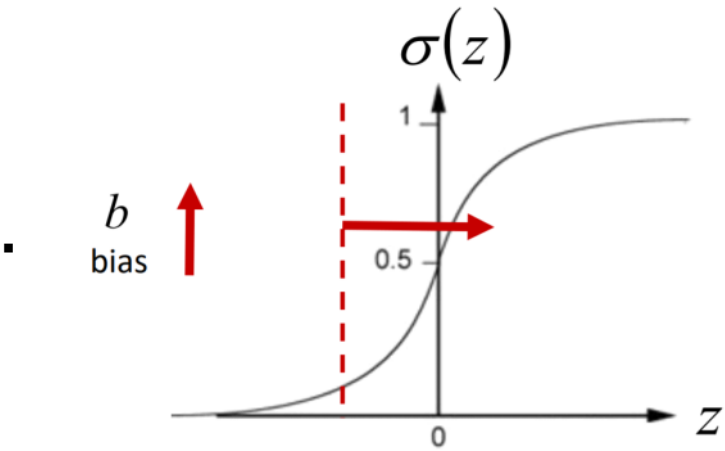

      The bias term gives a class prior
  - 同一層裡面的各neuron會是獨立的，但其實應該各種label都有dependency，所以一層是沒用的(沒有辦法互相share information)
    - 想要implement XOR的話就是要function的組合，簡單形狀的組合來模擬(hidden)，越多層情境越可以模擬(overfit?)，參數量越多越複雜
    - DNN: 很多層的MLP (FC)，多深要依據資料量、task難度而有不同情況
  - 兩個layer的weight會以matrix來表示
  - af:
    - 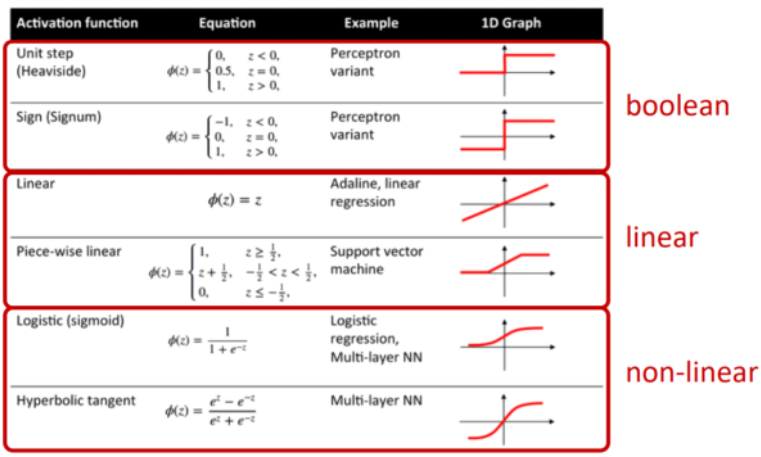

  - ReLU也是unbounded function，沒有理論說哪個好，但有常用的:

- 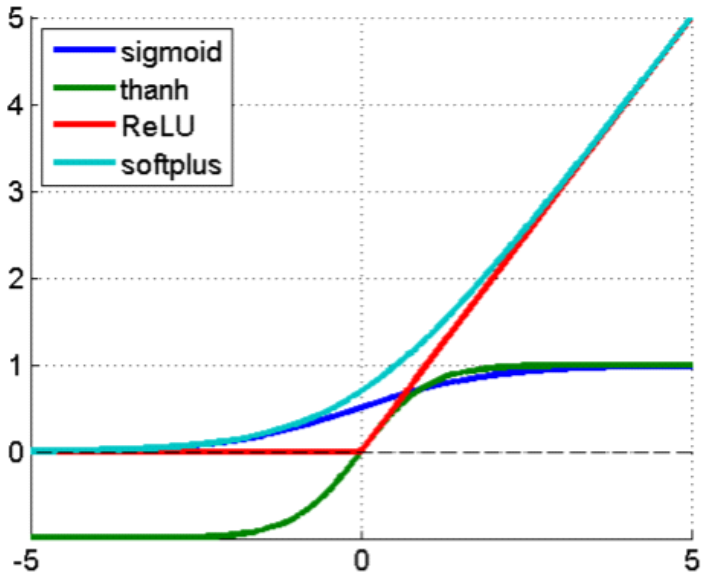

  tanh = thanh (-1~1)
  - 選non-linear的很重要，否則跟一層的linear transform會是一樣的，跌了很多層的linear會沒意義
- Loss function design 好的函式
  - maximize reward，minimize cost，希望可以接近真正y這個數值
    - 預測出來的y要跟真正的y越近越好，distribution要接近越好
  - cross entropy: output distribution越低越好，要跟真實的越近越好
  - square-loss: output是一個value的話要去相減算平方和

Square loss

$$C(\theta) = (1 - \hat{y} f(x;\theta))^2$$

Hinge loss

$$C(\theta) = \max(0, 1 - \hat{y} f(x;\theta))$$

  - Logistic loss

$$C(\theta) = -\hat{y} \log(f(x;\theta))$$

Cross entropy loss

$$C(\theta) = -\sum \hat{y} \log(f(x;\theta))$$

Others: large margin, etc.

- Optimization
  - DL常用GD
    - 可以用暴力法，但是用篇微分=0比較快，但其實會不知道整個space太大了不一定找的到，所以才用GD(全部的error加起來取平均)。但有些缺點所以有BP
    - 看完全部的data才去update會很慢，所以才有SGD
      - 看一個sample就先小update一次，每一次只找一個sample去看loss用篇微分update (假設所有sample取到的機率一樣uniform)，所有變化的平均，比GD更快速達到想要的點

- 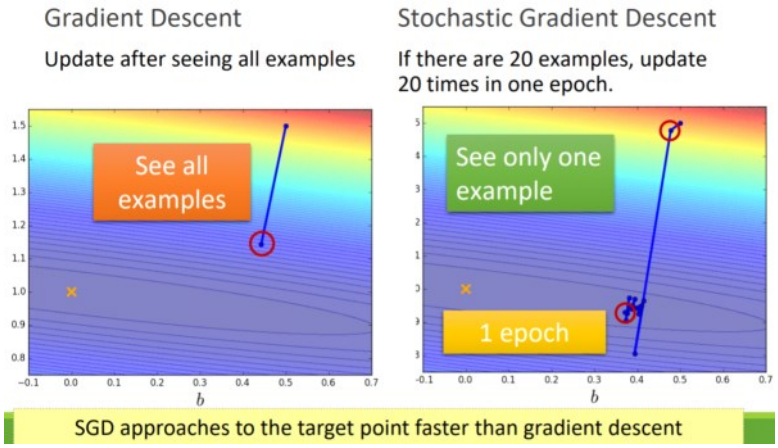

  - 每次挑一個batch去做update: mini-batch最快，SGD>GD
    - SGD acc最高，>minibatch>GD
    - 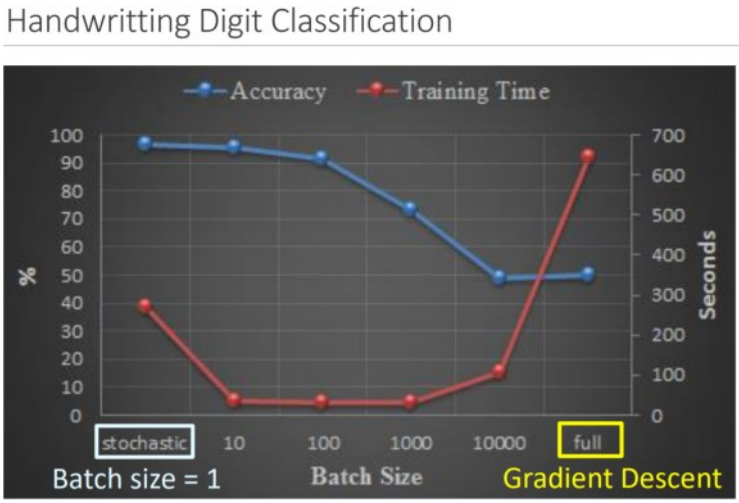

  - 實作tips:
    - 每次都從不同的點開始，random從不同開始的點找相對低點 (initialization要random) 才可以到global minima
    - lr: 離目標遠的時候大步一點，後期要小一點 才可以到local minima，adaptive lr自動調整
    - 每個epoch都要shuffle一次，才可以學到data真正的distribution，讓NN不是用背的順序
    - 每個epoch的batch size要固定，implement的時候訓練才會快
    - validation是為了模擬testing情境，去反應真的再使用之表現如何，根據validation去知道model performance
    - 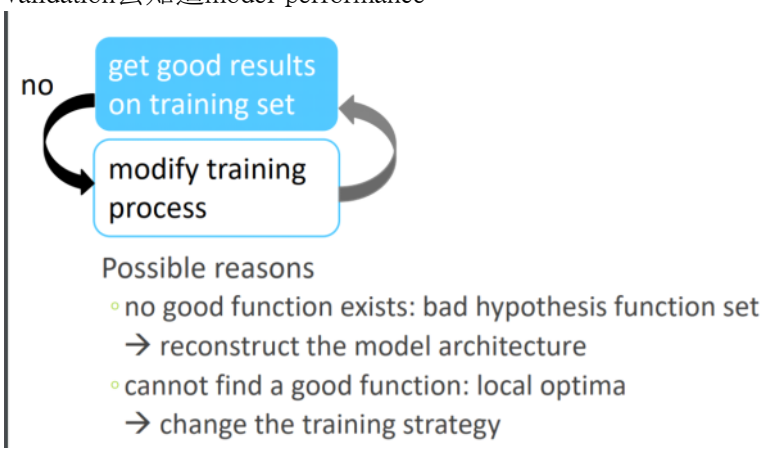

- 

Better performance on training but worse performance on dev → overfitting

  - Overfitting
    - 要去收集更多training data，加入dropout

HW tips:

- FastText、gensim、GloVe、w2v可以用來訓練embedding
- 前處理: SpaCy、NLTK
- 利用special token來分開這句話是誰說的，或是用不同speaker train不同的embedding再去concate
- RNN 可以最後變成一個vector輸出，或是用mean/max pooling (不然用個XGB看哪個維度重要變成weigted sum)
- 經過attention以後的vector可以把attention前的vector進行互動 EX: element-wise product跟element-wise 相減，再去concatenate然後在丟到下一層
- 比較兩個vector: inner product、MLP、cos-similarity
- loss: binary crossentropy、softmax不一定好
- SpaCy會去做一些前處理的function可以關掉以加速，其中 1:4/1:9的negative sampling比較好